

Zeit	Raum	Abgabe im Moodle; Mails mit Betreff: [SMD1718]
Di. 10-12	CP-03-150	philipp2.hoffmann@udo.edu und jan.soedingrekso@udo.edu
Di. 16-18	P1-02-110	felix.neubuerger@udo.edu und tobias.hoinka@udo.edu
Di. 16-18	CP-03-150	simone.mender@udo.edu und maximilian.meier@udo.edu

Aufgabe 12: *Zwei Populationen*

5 P.

Gegeben seien zwei Populationen von jeweils 10 000 Punkten in einer Ebene. Die Population P_0 sei eine zweidimensionale, korrelierte Gaußverteilung mit:

$$\mu_x = 0, \quad \mu_y = 3, \quad \sigma_x = 3,5, \quad \sigma_y = 2,6 \quad \text{und Korrelation} \quad \rho = 0,9$$

Die zweite Verteilung P_1 ist gegeben durch eine Gaußverteilung in x mit

$$\mu_x = 6 \quad \text{und} \quad \sigma_x = 3,5,$$

und einer Gaußverteilung in y , deren Mittelwert linear von x abhängt:

$$\mu_{y|x} = a + bx \quad \text{mit} \quad a = -0.5, b = 0.6 \quad \text{und} \quad \sigma_{y|x} = 1$$

- Zeigen Sie mithilfe der Formel für die bedingte Wahrscheinlichkeit der 2D Normalverteilung¹, dass die zweite Population ebenfalls einer 2D Normalverteilung entspricht. Geben Sie an, wie die Parameter μ'_y , σ'_y und ρ der 2D Normalverteilung aus den Parametern a , b und σ_y der 1D Normalverteilung der Population P_1 bestimmt werden.
- Stellen Sie die beiden Populationen zusammen in einem zweidimensionalen Scatter-Plot dar.
- Berechnen Sie die Stichproben-Mittelwerte und -Varianzen von x und y sowie die Stichproben-Kovarianz und den -Korrelationskoeffizienten für die Einzelpopulationen und die Gesamtheit beider Populationen.
- Erzeugen Sie eine weitere Population mit den Eigenschaften der Population P_0 , diesmal jedoch nur mit 1000 Punkten. Erstellen Sie anschließend ein HDF5-File mit drei Keys und speichern Sie die drei erzeugten Populationen unter eindeutigen Bezeichnungen ab.

¹Von Blatt 1, Aufgabe 4: Zweidimensionale Gaußverteilung

Aufgabe 13: *Trennende Geraden*

5 P.

Gegeben seien die Populationen P_0 und P_1 aus der Aufgabe „Zwei Populationen“. Nutzen Sie das dort erstellte HDF-File für diese Aufgabe. (Sie finden die Datei ebenfalls im Moodle.) Außerdem seien die Projektionsgeraden

$$g_1(x) = 0 \quad (1)$$

$$g_2(x) = -\frac{3}{4}x \quad (2)$$

$$g_3(x) = -\frac{5}{4}x \quad (3)$$

gegeben.

- Stellen Sie die beiden Populationen zusammen in einem zweidimensionalen Scatterplot dar und zeichnen Sie die drei Projektionsgeraden ein. Im Folgenden werden diese beiden Populationen mit P_0 und P_1 bezeichnet.
- Projizieren Sie die Punkte aus Population P_0 und P_1 jeweils auf die Geraden g_1 , g_2 und g_3 . Bestimmen und normieren Sie vorher den Projektionsvektor und wählen Sie das Vorzeichen so, dass die projizierte Population P_0 rechts (zu größeren Werten) von P_1 liegt. Stellen Sie die projizierten Populationen P_0 und P_1 für jede Projektion in einem eigenen, eindimensionalen Histogramm dar.
- Betrachten Sie P_0 als Signal und P_1 als Untergrund. Berechnen Sie die Effizienz und die Reinheit des Signals als Funktion eines Schnittes λ_{cut} in den projizierten Räumen und stellen Sie die Ergebnisse für jede Projektion in einem eigenen Plot dar.

Aufgabe 14: *Fisher-Diskriminante: Per Hand*

5 P.

Führen Sie eine lineare Diskriminanzanalyse nach Fisher per Hand durch.

Population 0: (2;2;1) (2;3;2) (2;1;2) (1;2;0) (3;2;0)

Population 1: (2,5;2,5;0) (2,5;1,5;0) (4;2;0) (5,5;2,5;0) (5,5;1,5;0)

- Berechnen Sie die Mittelwerte $\vec{\mu}$ und Streumatrizen S_i , sowie die Streuung innerhalb der Klassen und zwischen den Klassen (S_W und S_B).
- Berechnen Sie die Eigenwerte und Eigenvektoren der Matrix $S_W^{-1} \cdot S_B$.
- Wie lautet die Projektion $\vec{\lambda}$? Verifizieren Sie dies, indem Sie $S_W^{-1}(\vec{\mu}_0 - \vec{\mu}_1)$ berechnen.

- d) Projizieren Sie die Punkte der Populationen auf den Projektionsvektor (denken Sie an die Normierung). Skizzieren Sie die Positionen der einzelnen Punkte auf der Projektionsgeraden ($\vec{\lambda} \cdot \vec{x}_i$) (eindimensional).
- e) Wählen Sie einen geeigneten Parameter λ_{cut} und berechnen Sie die dazugehörige Effizienz und Reinheit. Warum haben Sie diesen Parameter gewählt?

Aufgabe 15: *Metropolis-Hastings-Algorithmus*

5 P.

- a) Zeigen Sie analytisch, dass der Metropolis-Hastings-Algorithmus für eine gaußförmige Schrittvorschlags-PDF in den Metropolis-Algorithmus übergeht.
- b) Implementieren Sie den Metropolis-Algorithmus um aus einer Gaußverteilung zu sampeln. Nutzen Sie dafür die in der Datei `MCMC_template.py` vorgegebene Klassenstruktur und implementieren Sie die vorgegebenen Methoden anhand ihrer Docstrings.
- c) Erzeugen Sie mit ihrer implementierten `sample`-Methode 10 000 Zufallszahlen aus einer Gaußverteilung mit $\mu = -3$ und $\sigma = 2$. Nutzen Sie `x_0 = 15` als Startwert und `step_size = 2` als Schrittweite. Vergleichen Sie die erzeugten Zufallszahlen mit der zugrundeliegenden Verteilung.
- d) Erzeugen Sie einen sogenannten „Trace Plot“, indem Sie die erzeugten Zufallszahlen gegen die Iteration, in der sie erzeugt wurden, auftragen. Interpretieren Sie das Ergebnis.