

## **Aufgabe 36**

Rechnung angehängen.

A36

$$a) g = A f, \quad A = \begin{pmatrix} 1-\epsilon & \epsilon \\ \epsilon & 1-\epsilon \end{pmatrix}$$

$$b) f = A^{-1} g, \quad A^{-1} =: B$$

$$B = (1-2\epsilon)^{-1} \begin{pmatrix} 1-\epsilon & -\epsilon \\ -\epsilon & 1-\epsilon \end{pmatrix}$$

$$f_{1/2} = (1-2\epsilon)^{-1} ((1-\epsilon) g_{1/2} - \epsilon g_{2/1})$$

$$c) \text{ Poisson} \Rightarrow \text{Pecor } \sqrt{n} = 7 \text{ Varianz } n$$

$$\text{Also } V[g] = \begin{pmatrix} g_1 & 0 \\ 0 & g_2 \end{pmatrix}$$

$$V[f] = B V[g] B^T = (1-2\epsilon)^{-2} \begin{pmatrix} (1-\epsilon)^2 g_1 + \epsilon^2 g_2 & -\epsilon(1-\epsilon)(g_1 + g_2) \\ -\epsilon(1-\epsilon)(g_1 + g_2) & (1-\epsilon)^2 g_2 + \epsilon^2 g_1 \end{pmatrix}$$

$$d) f_1 = 203,875, f_2 = 765,725, \quad f_1 + f_2 = 369 \checkmark$$

$$V[f] = \begin{pmatrix} 255,765625 & -57,890625 \\ -57,890625 & 277,075625 \end{pmatrix}$$

$$\sigma_{f_i} = \sqrt{(V[f])_{ii}}, \quad \sigma_{f_1} = 75,9926747$$

$$\sigma_{f_2} = 74,7374502$$

$$\rho = \frac{\text{cov}(f_1, f_2)}{\sigma_{f_1} \cdot \sigma_{f_2}} = -0,22025324337796553$$

$$e) f = (262, 707)^T \quad f_1 + f_2 = 369 \checkmark$$

$$V[f] = \begin{pmatrix} 2476 & -2274 \\ -2274 & 2327 \end{pmatrix} \quad \begin{aligned} \sigma_{f_1} &= 49,75942722 \\ \sigma_{f_2} &= 48,77675788 \end{aligned}$$

$$\rho = -0,9235597729758676$$

Durch Fehlerkategorisierungswahrscheinlichkeit wird das Ergebnis zufälliger, dies spiegelt sich in den höheren Fehlern und der (negativen) Korrelation wieder.

f) für  $\epsilon \rightarrow 0,5$  wird  $V[f]$  singular bzw.  $\rho \rightarrow 1$ .

Die Daten sind also vollkommen nutzlos, sie bekommen keine Information.

## Aufgabe 37

Rechnung angehängen.


a)

Es handelt sich um einen Messprozess, bei dem mit Wahrscheinlichkeit  $\varepsilon$  ein Ereignis fälschlicherweise in den nächst höheren oder niedrigeren Bin kategorisiert wird, und daher mit Wahrscheinlichkeit  $1 - 2\varepsilon$  in den korrekten (bzw.  $1 - \varepsilon$  für die Randbins).

c)

Die Eigenbasis hat, wie immer, den Vorteil, dass die Matrix hier diagonal ist daher lässt sie sich hier sehr leicht und stabil invertieren.

d)




**Abbildung 1:** Darstellung der Koeffizienten in Eigenbasis.

Die schwachen Eigenwerte kleiner als 1 sind, wie in Abbildung 1 zu sehen, sehr instabil. Diese werden zur Regularisierung deswegen auf null gesetzt.

e)

Die Lösung mit Regularisierung hat, wie in Abbildung 2 gut erkennbar, deutlich geringere Oszillationen. Außerdem sind ihre Fehler ebenfalls deutlich geringer.



**Abbildung 2:** Ergebnis der Entfaltung mit und ohne Regularisierung.

c)  $g = A f$ ,  $A = U \cdot D \cdot U^T \Rightarrow U$  hat die EVs  
als Spalten

$$\Leftrightarrow \underbrace{U^T}_{\tilde{g}} g = \underbrace{U^T U}_{I} \underbrace{D}_{\tilde{A}} \underbrace{U^T f}_{\tilde{f}}, \quad \tilde{A} = D$$

$$\Leftrightarrow \tilde{g} = D \tilde{f}, \quad \tilde{g} = c, \quad \tilde{f} = b \quad \text{laut Aufgabe}$$

$$\Leftrightarrow c = D b$$

d)  $V[g] = \text{diag}(s)$  (Position tauschen)

$$\Rightarrow V[c] = U^T V[g] U$$

$$\Rightarrow V[b] = D^{-1} U^T V[g] U D^{-1} \quad ((D^{-1})^T = D^{-1})$$


e)  $f = U b$

$$\Rightarrow V[f] = U V[b] U^T$$


## Aufgabe 38

a)


In den Histogrammen ist eindeutig erkennbar, dass das Attribut *size* die beste Korrelation mit dem Zielattribut *energy\_true* aufweist, daher wird *size* als Attribut zur Entfaltung gewählt.




**Abbildung 3:** Zwei-dimensionales Histogramm für die Attribute *energy\_true* und *size*.




**Abbildung 4:** Zwei-dimensionales Histogramm für die Attribute *energy\_true* und *cog\_x*.



**Abbildung 5:** Zwei-dimensionales Histogramm für die Attribute *energy\_true* und *cog\_y*.




**Abbildung 6:** Zwei-dimensionales Histogramm für die Attribute *energy\_true* und *cov\_x*.



**Abbildung 7:** Zwei-dimensionales Histogramm für die Attribute *energy\_true* und *cov\_y*.





**Abbildung 8:** Zwei-dimensionales Histogramm für die Attribute *energy\_true* und *leakage*.

b)


Die Migrationsmatrix  $A$  ist in Abbildung 9 dargestellt.

e)


Leider zu wenig Zeit, wir benutzen stattdessen einfach *scipy* zum Minimieren.

f)

Der Vergleich der verschiedenen Regularisierungsstärken in Abbildung 10 zeigt, dass die Regularisierung mit  $\tau = 0,001$  am angemessensten erscheint.



**Abbildung 9:** Grafische Darstellung der Migrationsmatrix.



**Abbildung 10:** Ergebnis der Entfaltung mit verschiedenen Regularisierungsstärken  $\tau$ .

b)  $S = A f$   $f: \mathbb{R}^0$ ,  $f = \text{true energy}$   
 24 bins, 720-500; 76 bins 75 bis 200  
 $A$  (so  $A$  ist  $24 \times 76$  Matrix)

c)  $p(k) = \frac{\lambda^k e^{-\lambda}}{k!}$   $g_i$  seien die Messwerte

$\lambda_i = A_i f$  also Likelihood;  

$$L = \prod_{i=1}^{24} \frac{\lambda_i^{g_i} e^{-\lambda_i}}{g_i!} = \prod_{i=1}^{24} \frac{(A_i \cdot f)^{g_i} e^{-A_i f}}{g_i!}$$

$$F = -\log L = \sum_{i=1}^{24} \left[ \log(g_i!) - g_i \log(A_i f) + A_i f \right]$$

d)  $F_{\text{reg}} = F + \frac{\tau}{2} \|P f\|^2$

$$\frac{\partial F_{\text{reg}}}{\partial f_i} = - \sum_{j=1}^{24} \left( g_j \frac{A_{ji} f_i}{A_j \cdot f} + A_{ji} f_i \right) + \frac{\partial}{\partial f_i} \left( \frac{\tau}{2} \left( \sum_{j=1}^{76} (P_j f) \right)^2 \right)$$

$$= - \sum_{j=1}^{24} A_{ji} \left( f_i \frac{g_j}{A_j f} \right) + \tau \sum_{j=1}^{76} (P_j f) \cdot P_{ji} f_i$$

$$\frac{\partial^2 F}{\partial f_i \partial f_j} = \frac{\partial}{\partial f_j} \left( \frac{\partial F}{\partial f_i} \right) = + \sum_{k=1}^{24} \left[ \frac{g_k}{A_{kj} f_j^2} + A_{kj} \delta_{ij} \right]$$

$$+ \tau \left( \sum_{k=1}^{76} P_{kj} f_j P_{ki} f_i + \delta_{ij} \sum_{k=1}^{76} (P_k f) P_{kj} \right)$$

Mit Sicherheit falsch, ich versuch gar  
 nicht erst das zu implementieren/derechnen  
 leider zu wenig Zeit.